



PREVISÃO IBOVESPA[®]

Prevendo a Tendência do Ibov

DESAFIO DO PROJETO

01 OBJETIVO DE PERFORMANCE

Desenvolver um modelo de classificação (Alta/Baixa) capaz de atingir uma acurácia mínima de 75% em um conjunto de teste fixo de 30 dias.

02 OBSTÁCULO: O RUÍDO DO MERCADO

O mercado financeiro é volátil e 'ruidoso'. Prever movimentos diários pequenos (ex: +0.01%) é estatisticamente o mesmo que 'cara ou coroa'.



IBOV. 146.824,00 +662 | +0,45%

DXY. 98,796 -0,140 | -0,14%

B\$. 116.030,00 +4730 | +4,16%

AQUISIÇÃO E EXPLORAÇÃO DOS DADOS

AQUISIÇÃO

Foram coletados 5 anos de dados diários do IBOVESPA (Out/2020 a Out/2025), totalizando 1247 pregões.

EXPLORAÇÃO

A exploração inicial mostrou que colunas críticas como Vol. (ex: '5,53B') e Var% (ex: '0,78%') foram lidas como texto, impossibilitando cálculos.

PRÉ-PROCESSAMENTO

Uma etapa de limpeza robusta foi executada para converter todas as colunas em formatos numéricos, tratar dados ausentes e ordenar a série cronologicamente.


FEATURE ENGINEERING

01 FEATURES LAGGED (MEMÓRIA)

Para dar 'memória' ao modelo, foram criadas colunas com os retornos dos dias anteriores (Lag_1, Lag_2, Lag_3). Isso permite ao modelo ver padrões de curto prazo.

02 JANELAS DESLIZANTES (CONTEXTO)

Para dar 'contexto', foram criados indicadores que resumem um período, como Médias Móveis (SMA) para ver tendência e o RSI para medir momentum.



PREPARAÇÃO DA BASE (ESTRATÉGIA VENCEDORA)

Uma boa feature não adianta se o alvo for ruim. Os testes iniciais (prevendo qualquer movimento) falharam (acurácia < 60%).

01 FILTRAGEM DE RUÍDO (THRESHOLD 0.5%)

Decidimos filtrar o 'ruído'. Definimos que um movimento 'significativo' era apenas $> 0.5\%$ (Alta) ou $< -0.5\%$ (Baixa).

02 DEFINIÇÃO DO TARGET E JANELA

Removemos todos os dias 'de lado' do dataset. Isso forçou o modelo a focar apenas em sinais fortes e reais. A janela de teste foi fixada nos últimos 30 pontos de dados.



REDUÇÃO DE RISCO

Ao filtrar o 'ruído', evitamos que o modelo fizesse previsões arriscadas em dias de baixa volatilidade. A estratégia aumentou a 'segurança' dos sinais gerados.




SINAL CONFIÁVEL

Um modelo que tenta prever 'cara ou coroa' (acerto de 50%) é inútil. Ao focar apenas em movimentos reais, nosso modelo saltou para 76,67%, provando ser uma ferramenta confiável para a tomada de decisão.

ESCOLHA E JUSTIFICATIVA DOS MODELOS

Com a base tratada, comparamos 3 classes de modelos para encontrar o melhor equilíbrio entre performance e generalização:

- 1. Regressão Logística: Um baseline linear para testar a força das features.
- 2. Random Forest: Um modelo ensemble não-linear, ótimo para capturar interações complexas.
- 3. XGBoost: Um modelo de boosting para buscar a máxima performance.



RESULTADOS (O MODELO É CONFIÁVEL?)


O Random Forest atingiu 76,67%. Analisamos sua Matriz de Confusão e métricas para garantir que ele é confiável e não 'viciado'.

01 PRECISÃO NA BAIXA (92%)

Quando o modelo prevê 'Baixa' (0), ele está 92% correto. É um sinal de 'NÃO OPERE' extremamente confiável.

02 RECALL NA ALTA (92%)

O modelo conseguiu identificar 92% (12 de 13) de todas as oportunidades reais de 'Alta' (1). Ele não perdeu oportunidades.



JUSTIFICATIVA TÉCNICA: O TRADE-OFF

01 ACURÁCIA VS. OVERFITTING

Overfitting é quando um modelo 'decora' o passado tão bem que falha em prever o futuro. O desafio é encontrar um equilíbrio.

02 A PROVA NO PROJETO

Nosso Random Forest Otimizado (66,67%) teve um desempenho pior que o Random Forest padrão (76,67%). A otimização causou overfitting, e o modelo padrão, mais simples, generalizou melhor.



IBOV. 146.824,00 +662 | +0,45%

DXY. 98,796 -0,140 | -0,14%

₹. 116.030,00 +4730 | +4,16%

OBRIGADO!

Dúvidas?

 /caiotorves

 caio@torves.com